

模块收官

AI 辅助的数据研究报告

模块五: 数据工程 (下)

第二十讲: 模块收官——AI 辅助的数据研究报告

[解释]

这节课做什么

前三讲各自解决了一个分析维度: L17 解决"谁多", L18 解决"分布如何", L19 解决"在哪里"。但这些产出是分散的图表和代码, 没有上下文。本讲的任务是把它们整合成一份有标题、有摘要、有图表、有结论的完整报告。AI 负责代码生成和文字润色, 你负责定义报告结构和审核结论是否合理。

一、碎片化产出的整合问题

图表、代码、发现——如何组装成一份报告？

[解释]

为什么不能只交图表

在课堂练习中，提交一段代码和一张截图就够了。但在学术或商业场景中，图表只是报告的一个组成部分。读者需要知道：数据从哪来、做了什么清洗、选择某种图表类型的理由是什么、图上的模式说明了什么问题、分析的局限性是什么。这些上下文信息，只靠图表本身传达不了。

一份数据研报应该包含什么

参考学术论文和商业咨询报告的通行格式，一份数据分析报告通常包含以下几个模块。

报告结构模板

1. **标题与摘要**：一句话概括分析目标和主要发现。
2. **数据来源与清洗**：数据从哪里获取、做了哪些过滤和预处理。
3. **描述性分析（①层）**：条形图/分组条形图展示全局排名和结构。
4. **分布与关联分析（②③层）**：箱线图展示组内差异，散点图+回归线揭示变量关系。
5. **空间分析（④层）**：地图标注、热力图、等值线地图展示地理分布。
6. **结论与局限**：主要发现总结、分析方法的不足。

Markdown 报告骨架

```
# 江西省旅游资源竞争力分析报告

## 1. 摘要
本报告基于去哪儿网 2026 年...

## 2. 数据来源与清洗
原始数据集包含 89,460 条记录...

## 3. 描述性分析
! [景区数量排名] (barh_jiangxi.png)
! [各星级占比] (grouped_bar_jiangxi.png)

## 4. 分布与关联分析
! [票价分布箱线图] (boxplot_jiangxi.png)
! [票价与销量关联] (scatter_jiangxi.png)

## 5. 地理分布分析
! [景区分布热力图] (heatmap_jiangxi.png)

## 6. 结论与局限
```

[解释]

报告的六段式结构

这个结构不是随意设计的，它参考了学术论文和咨询报告的通行格式。标题和摘要让读者在 30 秒内判断是否需要细读；数据来源和清洗说明增加可信度；三个分析章节按维度递进（总量→分布→空间）；结论和局限体现分析的完整性。Markdown 格式的好处是兼容性好——可以直接在 GitHub 上渲染，也可以转成 PDF 或 Word。

二、用 AI 生成分析文字

人定义结构，AI 填充内容

[解释]

人与 AI 的分工边界

报告写作中最适合让 AI 做的是"把数据翻译成段落"——给它箱线图的关键统计量（中位数、四分位距、异常值数量），让它输出一段结构化的分析文字。最不适合交给 AI 的是"结论的合理性判断"——AI 可能写出看似合理但实际上缺乏领域知识支撑的结论。因此分工是：人负责定义报告结构、审核结论、决定哪些信息值得写进去；AI 负责把确定的信息组织成流畅的段落。

Step 1: 提取图表的关键统计量

在让 AI 写分析文字之前，需要先用代码把图表背后的关键数字提取出来。AI 不能"看图"，但它能根据具体的数字写出分析。

需要提取的信息

- 各星级景区的数量和占比。
- 各星级门票的中位数和四分位距。
- 价格异常值的数量及具体案例（景区名称和票价）。
- 景区最密集的城市和最空白的区域。

提取代码示例

```
# 筛选江西省有星级、有票价的记录
jx = df[(df['province'] == '江西') &
        (df['level'] != '无') &
        (df['price'] > 0)]

# 各星级的数量
print(jx['level'].value_counts())

# 各星级的价格统计
print(jx.groupby('level')['price'].describe())

# 价格最高的 5 个景区
print(jx.nlargest(5, 'price')[['name', 'level', 'price']])

# 景区最多的城市
print(jx['search_city'].value_counts().head(5))
```

操作顺序：先运行代码拿到具体数字，再把这些数字作为上下文传给 AI。不要让 AI 凭空捏造统计量——它会编出看似合理但完全虚构的数据。

[解释]

为什么要先提取数字

大语言模型的一个已知局限是"幻觉" (Hallucination)：在缺少具体输入时，它会生成看起来合理但完全虚构的统计数据。因此，正确的做法是先用 Pandas 代码把关键数字算出来，然后把这些数字作为 Prompt 的一部分传给 AI。这样 AI 的工作就变成了"把确定的数字组织成通顺的段落"，而不是"凭空编造分析"。这个流程本身就是人机协同的典型模式：人负责确保数据真实，AI 负责文字表达。

Step 2: 用 Prompt 生成分析段落

把提取出的统计量作为上下文，让 AI 为每个章节生成分析文字。

Prompt 结构

- **角色**：数据分析报告的撰稿人。
- **背景数据**：直接把第一步算出的数字贴进 Prompt。
- **输出要求**：指定段落长度、语气（客观陈述，不要用感叹号）、需要覆盖的分析要点。

Prompt 示例

【角色】 数据分析报告撰稿人，语气客观专业。

【背景数据】

- 江西省有星级且有票价的景区共 287 个
- 5A 景区 12 个，中位票价 135 元
- 4A 景区 189 个，中位票价 68 元
- 3A 景区 86 个，中位票价 45 元
- 票价最高：庐山 180 元（5A）
- 3A 中有 2 个景区票价超过 200 元

【任务】

基于以上数据，为报告的“价格分布分析”章节撰写 2-3 段分析文字。需要覆盖：

1. 各星级的价格区间描述
2. 3A 景区中异常高价的现象及可能原因
3. 这一发现的实际意义

不要使用感叹号，不要使用“值得注意的是”等套话。

[解释]

Prompt 中为什么要限制语气

AI 在写分析文字时有两个常见问题：一是喜欢用感叹号和“令人惊讶”之类的情绪化表达，二是喜欢用“值得注意的是”、“不难发现”之类的套话。这些在公众号文章里常见，但在学术和商业报告中不合适。在 Prompt 里提前设定语气约束，可以大幅减少后续人工修改的工作量。另外，把具体数字直接写在 Prompt 中（而不是让 AI 自己去猜），是防止幻觉的关键措施。

三、完整工作流演示

从数据到报告的端到端流程

[解释]

四步流程概览

完整的报告生成流程是：

- (1) 从数据集中按省份过滤出目标子集；
- (2) 用 L17-L19 学过的方法生成三类图表（条形图、箱线图、地图）并保存为图片；
- (3) 用 Pandas 代码提取关键统计量（数量、中位数、异常值）；
- (4) 把统计量传给 AI，让它生成各章节的分析段落。最后把图片和文字组装进 Markdown 文件即可。

这四步的分工非常清晰：步骤 1-3 是代码驱动的确定性操作，步骤 4 是 AI 辅助的文字生成。

流程总览与分工示意

整个报告生成过程中，人和 AI 各自负责不同的环节。

人的职责

1. **定义分析框架**：决定报告的结构（六章节）和每章的分析目标。
2. **选择分析范围**：决定聚焦哪个省份、过滤什么条件。
3. **审核 AI 的输出**：检查生成文字中的事实是否与数据一致、结论是否合理。
4. **补充领域知识**：AI 写不出来的内容——比如“该地区景区密度低可能与地形有关”——需要人来补充。

AI 的职责

1. **生成代码**：根据 Prompt 生成过滤、统计、绑图的 Python 代码。
2. **渲染图表**：执行代码，生成条形图、箱线图、地图文件。
3. **撰写分析段落**：根据人提供的统计量，组织成结构化的分析文字。
4. **格式整理**：把图文组装成格式规范的 Markdown 文档。

核心原则：数据的真实性由人通过代码保证，文字的流畅性由 AI 辅助完成。如果反过来——让 AI 自己编数据——报告的可信度就归零了。

[解释]

人机分工的底线

记住一条原则：在数据分析中，AI 是“表达工具”而不是“数据来源”。让 AI 帮你把统计结果组织成流畅的段落没有问题，但让 AI 编造统计数字是严重的学术不端。这个原则不仅适用于本课程作业，也适用于未来的毕业论文和工作报告。

图表保存与 Markdown 组装

最后一步是把图表文件和 AI 生成的文字段落组装到一个 Markdown 文件中。

图表保存约定

- Matplotlib 图表用 `plt.savefig()` 保存为 PNG。
- Folium 地图保存为 HTML（地图截图可用浏览器截图工具获取）。
- 图片文件与 Markdown 文件放在同一目录下。

保存与引用代码

```
# 保存条形图
plt.figure(figsize=(10, 6))
# ... 绑图代码 ...
plt.savefig('barh_jiangxi.png',
            dpi=150, bbox_inches='tight')
plt.close()

# 保存箱线图
plt.figure(figsize=(10, 6))
# ... 绑图代码 ...
plt.savefig('boxplot_jiangxi.png',
            dpi=150, bbox_inches='tight')
plt.close()

# 在 Markdown 中引用
# ![景区数量排名](barh_jiangxi.png)
# ![票价分布](boxplot_jiangxi.png)
```

savefig 的两个参数： `dpi=150` 控制图片清晰度（150 对于报告已经足够），`bbox_inches='tight'` 自动裁剪图表周围的空白区域，避免报告中出现大片留白。

[解释]

图表保存的细节

`plt.savefig()` 在调用时必须放在 `plt.show()` 之前，否则画布已经被清空，保存出来的是一张白图。
`plt.close()` 的作用是释放内存——如果连续生成多张图表但不关闭，Python 进程的内存占用会持续增长。
`bbox_inches='tight'` 在插入报告时效果明显，因为 Matplotlib 默认会在图表四周保留一圈空白，裁掉之后报告的视觉效果更紧凑。

四、模块总结与模块作业

回顾本模块的知识体系与最终交付要求

[解释]

模块回顾和作业说明

这一页把四讲的知识线索串在一起，帮你看清整个模块的全景，同时明确最终作业的交付标准和评分依据。

模块五知识体系回顾

四讲内容形成了一条从数据采集到报告交付的完整链条。

四讲递进关系

- **L17 总量排名**：用 Matplotlib 画条形图，回答"谁的景区最多"。学会了基础绑图和中文字体配置。
- **L18 分布分析**：用 Seaborn 画散点图和箱线图，回答"多的那些质量怎样"。发现了聚合统计的遮蔽效应。
- **L19 空间分布**：用 Folium 画标注图和热力图，回答"它们在哪里"。引入了地理坐标维度。
- **L20 报告整合**：用 AI 把前三讲的产出组装成完整的数据研报。完成了"从分析到交付"的最后一步。

Prompt 策略的演进

讲次	Prompt 重心	原因
L17	格式调整	Matplotlib 默认样式粗糙
L18	清洗逻辑	Seaborn 自带样式，省下的空间描述过滤条件
L19	空间描述	新增坐标、缩放、图层等地理参数
L20	数据→文字	AI 根据统计量生成报告段落

[解释]

四讲的知识线索

这张递进表展示了贯穿整个模块的主线：分析维度从总量到分布到空间再到整合，Prompt 写法从管格式到管清洗逻辑到管空间描述再到管内容生成。Prompt 策略的变化说明："写 Prompt"不是一种固定技能，而是需要根据工具特性和分析目标灵活调整的能力。

模块收官作业

提交一份基于本周数据集的完整 Markdown 数据研究报告。

作业要求

- 1. 选择一个省份作为分析对象。
- 2. 报告必须包含前述六章结构（标题与摘要、数据来源、总量分析、分布分析、空间分析、结论与局限）。
- 3. 每个分析章节至少包含一张图表和两段以上的文字分析。
- 4. 明确标注哪些文字是 AI 辅助生成的（可在段落末尾加注 [AI 辅助]）。
- 5. 结论章节必须包含对分析局限性的讨论。

参考标准

维度	权重	说明
数据处理	25%	过滤条件合理、代码可复现
图表质量	25%	图表类型选择得当、标注清晰
分析深度	30%	是否发现了有价值的规律或异常
报告完整性	20%	结构完整、逻辑连贯、包含局限性讨论

[解释]

作业怎么评分

作业要求标注哪些段落是 AI 辅助写的，这是学术诚信的基本要求。评分权重中"分析深度"占比最大（30%）——如果你只用一张图就发现了票价异常的规律并给出了合理解释，比用五张图但只做表面描述的得分更高。看重的是你的独立思考和发现问题的能力，不是图表数量或文字的华丽程度。