

数据可视化入门

模块五 · 数据工程（下）

模块五: 数据工程 (下)

第十七讲: 数据可视化入门与基础实践

[解释]

本讲概览

这一讲是作图的入门课。我们要回顾数据集、理解为什么要用图表、学会用代码画第一张统计图，并借助 AI 提升图表表现力。通过了解眼睛看图和大脑读字的生理区别，大家会明白，画图不是为了让报告排版更漂亮，它是帮看报告的人快速发现规律的基础工具。

一、从一个真实问题出发

你的专业问题，也许一张图就能回答

[解释]

这一节在做什么

这一节从一个简单的问题开始："哪个省旅游资源最丰富？"用 `groupby` 统计就能得到答案。但统计结果只是一串数字——图表让这些数字变成直观的对比，一眼就能看出差距有多大、排名如何分布。后面几讲还会用图表回答更复杂的问题，比如"票价分布是什么形状"、"价格和销量有没有关系"——这些问题光靠统计数字是看不出来的。

同一份数据，不同专业看到不同的问题

今天的主题是数据可视化分析。对于同一份全国景区数据，不同专业背景的人，关心的问题完全不同：

每个人都有自己的问题

旅游管理 — 高等级景区（5A/4A）的分布和交通、经济水平有没有关联？为什么有些省份景区多但高等级少？

经济与管理 — 各省旅游资源密度和地方经济发展水平之间，呈现什么样的关系？

师生个人出行 — 有没有票价低、评分高、但知名度不高的小众景区？寒暑假可以去哪里？

地理与生态 — 自然景观类景区集中在哪些地带？和地形、气候有没有明显的对应？

但表格无法直观回答这些问题

打开文件，看到的是这样的内容：

province	name	level	price
甘肃	贵清山旅游风景区	4A	50
甘肃	遮阳山旅游风景区	4A	40
甘肃	首阳山景区	4A	15
...	...	...	...

12 万行数据，光靠肉眼扫描表格，左边这些问题一个都看不出答案。

表格存储数据，图表暴露规律。

接下来三讲分别从描述性分析、分布与关联分析、空间分析三个层次展开，第四讲独立完成一份综合研究报告。

[解释]

四个问题和后续四讲的关系

这一页列出了四个不同角度的旅游数据问题。它们不是随便选的——每个问题对应后续一讲的分析工具："谁最丰富"用条形图回答（本讲），"票价分布"用箱线图回答（L18），"空间聚集"用地图回答（L19）。不管你是什么专业背景，总能从中找到一个让你感兴趣的切入点。

底部那句"表格回答不了"很重要：12 万行数据用肉眼看表格是不可能看出规律的，这就是为什么需要图表。数据来源的采集脚本在 data/ 文件夹里，感兴趣可以自己看看。

行业是怎么做旅游数据分析的？

在学画图之前，先看看专业机构产出的旅游市场洞察报告长什么样。

携程《2025 中国入境游年度报告》

- 用**条形图**对比各客源国订单增幅（俄罗斯 +205%）
- 用**热力地图**展示入境游客在华活动轨迹的"下沉"趋势
- 用**折线图**呈现免签政策推动的月度增长曲线

中国旅游研究院《2025 年度报告》

- 全年出游 65.22 亿人次，用**堆叠柱状图**拆分城镇 vs 农村
- 用**等值线地图**展示各省旅游收入的地理分布差异
- 用**雷达图**多维度对比不同区域的旅游竞争力

去哪儿大数据研究院

- 用**流向图**可视化"奔县游"客源流动方向
- 用**分组柱状图**对比"银发族" vs "Z 世代"出游偏好
- 用**漏斗图**分析从搜索→预订→入园的转化率

这就是我们的目标

这个模块结束时，你将能用 AI 生成类似水平的分析图表，并组合成一份完整的旅游数据研究报告。你不需要记住任何 API，只需要学会提出正确的分析问题。

[解释]

为什么先看行业报告


在开始学具体技术之前，先看看专业报告长什么样。这样你就知道学完之后能做出什么——这些报告里的可视化图表，用的就是后面几讲会学到的工具和方法。

这里引用了三份来源：携程和去哪儿是 OTA 平台的数据报告，旅游研究院是官方研究机构。三个来源覆盖了行业的不同视角，后面看到"七层分析"时你会发现，报告里确实就在用这些方法。

三份权威报告的可视化实例

携程入境游报告

2025年各客源国入境游订单增幅




客源国订单增幅对比（条形图）

趋势基于公开报道，具体数值仅供教学示意

去哪儿五一出游报告

2025五一不同年龄群体出游增长率对比




"银发族" vs "Z世代"出游偏好对比（分组柱状图）

趋势基于公开报道，具体数值仅供教学示意

旅游研究院年度报告

2020-2025年国内旅游出游人次（亿）

数据来源：文化和旅游部统计公报（2025年为预测值）



全年城镇 vs 农村出游人次（堆叠柱状图）

数据来源：文化和旅游部统计公报

[解释]

从行业报告中中学到的分析思路

这三份行业报告展示了专业团队如何用可视化讲数据故事。注意一个共同点：每张图表都在回答一个明确的分析问题（“哪几个省份最热门”“趋势是上升还是下降”），而不是随机选图表类型。这就是“问题驱动型可视化”的核心原则——先确定想回答什么问题，再选择最适合的图表。后续的七层分析模型会系统化地拆解这个思路。

二、物理限制与作图原理

为什么看图表比看表格更快？

[解释]

为什么我们要作图


大家可能会觉得，既然数据已经算出来了，直接把表格发给别人不就行了？这一章我们从人的生理反应出发，讲一讲为什么要多此一举去画图。当数据量变大时，人脑读数字是非常慢的。弄懂这个原因，你以后在工作中汇报，就不会去放一大堆干巴巴的数字大表格了。

从生理机制看待作图的必要性

把数据变成图形，相当于跳过大脑的语言处理区，直接刺激视觉神经。

读文字的生理局限

- 人的短时记忆容量很小，一次只能记住七个左右的数字组合。
- 只要表格行数超出屏幕，人脑就很难在大脑里建构出整体全貌，看后面的就会忘前面的。



本能的视觉处理 (Preattentive Processing)

- 眼睛能在极短的时间内（不到一秒），瞬间看出一堆柱子里面谁最高、谁最长。
- 可视化的核心价值就在于：不需要仔细读字，一眼就能看清数据的占比和高低。

💡 **双重编码理论 (Dual-coding)：** 图表和文字分别进入了人脑的两个不同通道。结论告诉我们，将图配合上精准的文字说明，别人吸收这段信息的速度是最高的。

[解释]

为什么图表比表格更高效

这一页的核心在于两个认知科学概念。第一个是短时记忆限制 (Miller's Law, 7 ± 2)：人一次最多处理约 7 个独立数据项，超出屏幕的大表格会导致“前读后忘”。第二个是前注意加工 (Preattentive Processing)：人眼对长度、颜色、位置等视觉属性的感知是自动的、不需要逐字阅读的，所以看柱状图比扫描数字矩阵快一到两个数量级。底部的双重编码理论进一步说明：图表搭配文字注释能同时激活视觉和语言两个认知通道，信息吸收效率最高。

怎么把数据映射成对应的图形？

作图的本质，是给每一列数据匹配最合适的表现形式。选错图表类型会导致信息失真。

1. 弄清数据的性质

- **类别型 (Categorical)**：比如“江西”、“5A景区”。这类数据只用来区分，不能用于数学相加。
- **数值型 (Quantitative)**：比如销量、价格。它们确实存在真实的数字大小关系。

2. 挑选合适的图形元素

- **位置结构**：用来表达数值之间的走势对应关系（好比各类散点图）。
- **纵向长度**：用来简单地比较几类别的大和小关系（最常见的就是长条形的柱子）。

⚠ **常见作图失误**：人眼实际上对圆形的倾斜角度非常不敏感。如果要比较十几个份额差不多或者相近的省份，请不要使用大饼图（Pie Chart），优先选择单纯对比长短的条形图。

[解释]

怎么给数据选对图形

画图不能全凭喜好，要看数据的性质。“类别型”数据（比如省份）和“数值型”数据（比如票价）的组合，最保险的画法是用柱子比长短。很多人喜欢用圆形的饼图，但实际上，人眼对圆的夹角大小很不敏感，十几个省份混在一个小圈圈里根本看不清。老老实实用条形图比较长度，才是正规报告里最稳妥的做法。

可视化分析的七个层次

做数据分析，不是随便画张图。全球顶尖高校的可视化课程都遵循同一套分析层次模型。先确定你要回答什么层次的问题，再让 AI 推荐合适的图表。

分析层次	核心问题	典型图表
① 描述性分析	现状是什么？谁多谁少？	条形图、Treemap、词云
② 分布分析	数据集中在哪里？有没有异常？	直方图、箱线图、小提琴图、密度曲线
③ 关联分析	变量之间有什么关系？	散点图、相关性热力矩阵、气泡图、回归线
④ 空间分析	地理上有什么聚集或空白？	地图标注、热力图、等值线地图
⑤ 比较分析	不同组之间差异有多大？	分组箱线图、雷达图、平行坐标图
⑥ 流向/构成分析	从哪来到哪去？层级结构？	桑基图、旭日图、Treemap
⑦ 综合叙事	如何讲一个数据故事？	多图组合 + 注释 + 叙事结构

本模块的路线：L17 从第①层入手，L18 覆盖②③层，L19 覆盖④层，L20 由学员独立综合运用①—⑦层完成一份研究报告。图表由 AI 生成，你的职责是判断该用哪个层次的分析来回答你的问题。

[解释]

七层分析表怎么用

这张表是整个可视化模块的"导航地图"。后面四讲不是按图表类型来的 ("今天学条形图，明天学箱线图")，而是按分析层次来的 ("今天回答'谁多谁少'，明天回答'有什么规律'")。每学完一讲，回来在这张表上标记一下自己掌握了哪一层。

七个层次从简单到复杂：①描述是最基础的排名统计，②分布看数据的整体形状，③关联看两个变量之间的关系，④空间把数据放到地图上。⑤⑥主要靠 AI 协作来扩展。最后 L20 写研究报告时你会回来查这张表，决定报告中应该用哪几个层次的分析。

三、Matplotlib 基础入门

画出第一张统计图表的必经之路

[解释]

开始动手画图

前面的认知理论弄明白了，现在正式动手进代码环境。这章主要教大家怎么用 Python 里最经典的两个库（Pandas 和 Matplotlib）相配合。我们会走过从数据进来到变成图像出去的三个必经关卡：配置字体字典、将零散文件计算为总数、调整作图语言出图。

绘制图形前的中文字体匹配

Matplotlib 是 Python 里最基础的画图库。它底层默认只兼容英文字符，所以在做图前必须先指定电脑里的汉字显示库。

为什么需要额外配置？

如果不加上这几行全局设置代码，图表里所有中文（省份名、标题等）都会显示为方块乱码，连负号也会出错。这是每次写分析脚本的起手操作。

导入库与字体配置

```
import pandas as pd
import matplotlib.pyplot as plt

# 指定中文字体 (Windows 使用 SimHei, Mac 使用 Arial Unicode MS)
plt.rcParams['font.sans-serif'] = ['SimHei', 'Arial Unicode MS']
# 确保负号正常显示
plt.rcParams['axes.unicode_minus'] = False

# 加载数据集
df = pd.read_csv('qunar_full.csv')
print(f"数据加载完成, 共 {len(df)} 条记录")
```

起手式： 这两行配置代码（两个字体 + 一行负号修正）在每次新建分析脚本时都要写在最前面。建议存为代码片段直接复制。

[解释]

第一步：设置中文字体

我们用的 Matplotlib 系统库起源于英语国家，它默认是不认识中文结构的。如果不加上这两行修改字库的配置，后面你画出来的图上所有的省份名字和标题全都会变成一个一个方块乱码。不要去费心思死记硬背这个变量名，把它当成是做图表前的起手式复制带走就可以了。

数据概览：先认识你手里的表格长什么样

在画任何图之前，第一件事永远是：看看数据长什么样。

`df.head()` — 看前 5 行

```
df.head()
```

name	province	search_city	level	price	...
西湖	浙江	杭州	5A	0	...
灵隐寺	浙江	杭州	-	45	...
千岛湖	浙江	杭州	5A	150	...
...	...	...	...	...	...

快速了解每一列是什么含义、数据的样子。

`df.info()` — 看整体结构

```
df.info()
```

```
RangeIndex: 125619 entries, 0 to 125618  
Data columns (total 14 columns):  
name           125619 non-null object  
province       125619 non-null object  
search_city    125619 non-null object  
level          40513 non-null object  
price          125619 non-null float64  
sale_count     125619 non-null int64  
lng            122104 non-null float64  
lat            122104 non-null float64
```

一眼看出：共 12.5 万条、14 列；`level` 大量缺失；`price` 是数值型。

养成习惯：拿到任何数据集，先跑 `head()` 和 `info()`。这两个命令就是你的“数据体检报告”。

[解释]

为什么要先看数据

在做任何分析之前先“看”一眼数据，是数据分析的基本习惯。`head()` 让你看到具体内容长什么样，`info()` 告诉你有多少行、每列是什么类型、有没有缺失值。这两个命令以后每次拿到新数据都建议先跑一遍。

表格中展示的字段也为后面的操作做了铺垫——你看到 `province`、`price`、`lng`、`lat` 这些列名，就能理解后面为什么用 `province` 做分组统计、用 `price` 做分布分析、用经纬度做地图标注。

绘制图形前的数据汇总（Groupby）

画图引擎没法直接消化十几万行的明细记录。在画图之前，必须先用工具把数据按类别汇总好。

分组汇总三步走 (Split-Apply-Combine)

1. 拆分：按省份名称把数据切成若干组。
2. 运算：分别计算每个省有多少条景点记录。
3. 合并：把结果拼回一张汇总表，按数量排序。

输出可用的目标对象

```
# 按省份分组计数，从大到小排序，取前10名
# sort_values 确保结果按数量降序排列
top_provinces = df.groupby('province')['name'].count() \
                  .sort_values(ascending=False).head(10)

print(top_provinces)
# 会整理出这样清洁且一一对应的内容形态：
# province
# 广东      11584
# 浙江      10414 ...
```

关键思路： 作图代码执行报错，绝大多数是因为喂进去的数值表格式对不上！事先用分组把杂质过掉、算成干净的统计量是顺利画板的前提工程。

[解释]

第二步：把明细汇总成统计项

很多初学者一上来就会犯一个毛病：拿到十几万行明细表，就想直接塞给作图函数渲染出来，这绝对会报错。作图引擎必须要确切汇总好的数字，所以必须要先用 Pandas 按省份分组。这里的意思就是按省份把它切开、算好总数，随后得出右下方那种干净紧密的省份对照结果表用于后面的输送准备。

水平条形图的实用价值与构建法则

利用上一步算好的汇总数据，传入作图函数生成图表。

为什么推荐多采用横放？

如果用竖向柱状图

(`plt.bar`)，一旦名称较长(比如"新疆维吾尔自治区")，底部的标签文字就会互相挤在一起，完全看不清。改用水平条形图(`plt.barh`)，每个省名独占一行，再长也摆得下。

作图代码

```
# 1. 创建画布，设置宽高
plt.figure(figsize=(10, 6))

# 2. 画水平条形图，传入分组标签和数值
plt.barh(top_provinces.index, top_provinces.values, color='#4A90E2')

# 3. 反转 Y 轴：让数量最大的排在最上面
plt.gca().invert_yaxis()

# 4. 添加标题和坐标轴标签，显示图表
plt.title('2026 景区数量 Top 10 省份', fontsize=14)
plt.xlabel('景区数量')
plt.show()
```

特别注意： `invert_yaxis()` 是一道保险程序。由于默认绘图机制从下位算起，若不加以反转处理，最大的第一名将被放置显示到图表基线的最底端。

[解释]

第三步：写执行代码出图纸

把刚才汇总好的材料喂给这里提供的这段作图代码就可以出图了。课件特意选了横向伸展的水平柱状图 (`barh`)，这是为了防止类似自治区等行政单位名字太长而导致挤在一起难以认明。另外，我们加了一句叫 `invert_yaxis` 的指令来把坐标轴互置反转；不加的话，那个最高的霸主柱状会默认被软件压着沉在视窗底面，这极其违反平日正常的查看直觉。

实际对比：竖向柱状图 vs 水平条形图

同一组数据，换一种画法，可读性完全不同。

竖向柱状图 `plt.bar`

```
plt.figure(figsize=(10, 6))
plt.bar(top_provinces.index,
        top_provinces.values)
plt.xticks(rotation=45, ha='right')
plt.title('景区数量 Top 10')
plt.show()
```

- X 轴标签需要旋转 45 度才能勉强显示
- 名称越长越拥挤，超过 6 个字就开始重叠
- 适合类别名称短且少的场景（如月份、季度）

水平条形图 `plt.barh`

```
plt.figure(figsize=(10, 6))
plt.barh(top_provinces.index,
          top_provinces.values)
plt.gca().invert_yaxis()
plt.title('景区数量 Top 10')
plt.show()
```

- 每个省名独占一行，无论多长都摆得下
- 从上到下阅读，符合排行榜的自然习惯
- 推荐用于类别名称较长或数量较多的场景

💡 **经验法则：** 当类别标签超过 4 个汉字，或者类别数量超过 6 个时，优先选择水平条形图。

[解释]

什么时候用竖向、什么时候用横向

竖向柱状图在类别名称较短时没问题（如 Q1/Q2/Q3/Q4），但遇到中文省份名就会因为标签太长而挤在一起。左侧代码中 `rotation=45` 是一种常见的补救办法——把标签斜过来，但效果并不理想。水平条形图（`barh`）天然解决了这个问题，所以处理中文类别名时建议默认用 `barh`。


实操预期：各省旅游目的地数量排名

分析目标

在 Notebook 中完成 Part 1 的实操，你应该得到类似右图的效果。

参考 Prompt

请用 pandas 统计 province 列的频次，取 Top 15，画一张横向条形图。标注每个柱子的具体数值。用 steelblue 颜色，标题为"全国各省旅游目的地数量排名"。



思考

1. 排名第一的省份有多少个景区？你的家乡排在第几位？
2. 景区数量排名等于"旅游热度"吗？

[解释]

怎么用这一页

右侧的图表是你在 Notebook Part 1 中应该得到的结果。如果你跑出来的图和这张不一样，检查一下数据文件是否加载正确、字段名称是否匹配。参考 Prompt 可以直接复制给 AI，也可以用自己的话改写。思考题帮你从“看懂图”进阶到“质疑图”——排名靠前不等于旅游热度高，可能只是数据源收录的景区多。这个质疑会在第 18 讲中被进一步验证。


向 AI 追问——景区多的省份，质量也高吗？

刚才的条形图告诉我们"哪个省景区最多"。但数量多不等于质量高。追问一步：这些省份的 5A/4A/3A 景区各占多少？

Prompt

我有一份景区数据 df，包含 province 和 level 字段。
请画一张分组条形图，展示景区数量
排名前 8 的省份中，各星级（5A/4A/3A）
的景区数量对比。

AI 生成的分组条形图



你会发现什么？

- 景区总数第一的省份，5A 景区不一定最多
- 有些省份 3A 占比极高——总量高是靠低等级撑起来的
- 少数省份 5A 占比突出——"小而精"

分析层次的升级

刚才	现在
① 描述性分析	⑤ 比较分析
谁多谁少	同一维度内部的结构差异

同一份数据，多问一步，洞察完全不同。

[解释]

为什么要"追问一步"

前面画的条形图回答了"哪个省景区最多"（第①层描述分析），但"多"不等于"好"。这一页通过向 AI 追问一步，得到分组条形图，把分析层次提升到第⑤层（比较分析）。核心在于三点：

1. 同一份数据，换一种问法，图表不同，结论也不同
2. 分组条形图不需要手写代码——一条 Prompt 就能生成
3. "景区多 ≠ 质量高"——这是数据分析中常见的发现，后面还会反复遇到

思考与讨论：从描述分析到比较分析

观察图表

1. 目的地总数排名第一的省份，5A 景区是不是也最多？
2. 哪个省份的 5A 占比最高（"小而精"）？
3. 哪个省份主要靠 3A 撑起了总量（"大而散"）？

深度思考

4. 如果你是旅游投资人，"总量多"和"5A 占比高"哪个更有价值？
5. 为什么同样的数据，换了一种问法，结论就完全不同了？
6. 这个发现对应可视化七层分析中的哪个层次？

[解释]

为什么换了问法结论就变了

前三题考察的是读图能力：你能不能从这张分组条形图中提取出具体的结论。后三题要求你往回想一步：之前画普通条形图时，结论是"某省景区最多"；现在换成分组图，结论变成了"它主要靠 3A 在撑数量"。同一份数据，问法不同，结论就完全不同。第 6 题让你回顾一下"可视化七层分析"那张表，找到这种"拆开看内部结构"的操作对应哪一层。

四、人机协同：你想清楚，AI 来写

把精力花在分析决策上，代码交给 AI

[解释]

改变以往手敲指令的工作模式

刚才咱们自己手码的指令语句仅仅是可以绘出一张比较原始粗陋的黑框直排表。而在大企业或是答辩现场汇报时，还得给里面调整颜色，并且手动去除一些无必要的黑线框等边缘操作。为了不做这个繁琐难查字典的死板事，我们接下来将这一套外包转出。

人与 AI 的分工协作法则

像去掉多余的边框、用循环代码为每根柱子标注具体数值这类事务，交给大模型一次搞定即可。

人负责分析决策

- 决定分析什么问题——比如"对比各省景区数量"还是"对比各星级的票价分布"。
- 决定数据范围——取全国还是某个省，取前 10 名还是全部。

AI 负责代码实现和样式

- 根据你的分析意图选择合适的图表类型和参数。
- 处理所有样式细节：配色、去边框、标数值、调字号——这些不需要你操心。

Prompt 示例

【分析目的】对比全国各省的景区数量差异，找出排名前 10 的省份。
【已有数据】变量 `df` 是完整的景区数据表，包含 `province` 字段。
【输出要求】画一张水平条形图，数量最多的排在最上面，图表风格简洁专业。



💡 **思维突破：** 把这段描述发给大模型，它很快就能生成几十行包含循环标注和样式调整的完整美化代码。操作者只需专注于规划和审核结果，不再需要亲自逐行查 API 文档。

[解释]

如何用 Prompt 让 AI 帮你画图

这一页展示了向 AI 发送绘图请求的标准结构：第一，说清分析目的（"对比各省景区数量"）；第二，告知已有数据（变量名 `df`、字段名 `province`）；第三，指定图表类型和样式要求（水平条形图、数量最多排最上面）。这种结构化描述能让 AI 一次性生成可运行的完整代码，远比自己逐行查 Matplotlib 文档高效。

五、课堂实践

用自己家乡的数据画一张图

[解释]

为什么用家乡省份的数据

这是本讲唯一需要你独立动手的环节。你需要把前面学到的"过滤→统计→画图→AI 美化"这条完整链路自己走一遍。之所以用你家乡省份的数据，是因为看到自己城市出现在排名中时，你会更在意数据是否合理——这种关注度有助于你发现数据中的问题。

实践任务：家乡景区数量排行图

利用前面学到的全部方法，在 5 分钟内完成一张家乡省份的城市景区排名图。

第一步：过滤省份

```
# 把"江西"替换为你家乡的省名
my_province = df[df['province'] == '江西']
print(f'共 {len(my_province)} 条记录')
```

第二步：按城市统计并取前 10

```
city_counts = (my_province
                .groupby('search_city')['name']
                .count()
                .sort_values(ascending=False)
                .head(10))
print(city_counts)
```

第三步：画横向条形图

```
plt.figure(figsize=(10, 6))
plt.barh(city_counts.index, city_counts.values)
plt.gca().invert_yaxis()
plt.title(f'xxx省 景区数量 Top 10 城市')
plt.xlabel('景区数量')
plt.show()
```

第四步：让 AI 美化

把代码和图表截图发给大模型，附上一句话：

"请帮我美化这张图：去掉上边和右边的框线，给每根柱子右边标上数字，颜色换成渐变蓝色。"

提交方式： 将最终美化后的图表截图提交到课堂互动系统。过滤省份时只需改引号内的省名。如果遇到中文乱码，检查是否漏写了字体配置的两行代码。

[解释]

三段代码各做了什么

三段代码合起来就是前面演示的完整链条：第一段过滤出你家乡省份的数据，第二段按城市统计景区数量，第三段画成水平条形图。之所以拆成三步而不是一次性给一大段，是为了让你清楚每一步在做什么。第四步"让 AI 美化"需要你自己构造一条 Prompt——想想你希望改什么颜色、加什么标题、去掉哪些多余的线条。


实操预期：全国收费 vs 免费占比

分析目标

在 Notebook 中完成 Part 4，验证收费和免费景区的比例。

参考 Prompt

请统计 df 中 `price > 0` 和 `price = 0` 的记录数，画一张饼图，标签为"收费"和"免费"，显示百分比，颜色分别用橙色和蓝色。



🔪 思考

1. 免费景区的占比比你预想的高还是低？
2. 只分析收费景区时，样本量会缩水多少？

[解释]

免费景区的占比为什么重要

这张饼图告诉你一个重要信息：数据集中免费景区占了相当大的比例。这意味着，如果后面你想分析“票价分布”，就必须先过滤掉 `price=0` 的记录——这样会损失相当一部分数据量。样本量减少会影响统计结论的可靠性，这是下一讲数据清洗环节需要考虑的问题。

本讲总结思考

技能回顾

1. 今天用了两种条形图（普通和分组），它们分别回答了什么层次的问题？
2. 在 Part 4 中，你的 Prompt 和 AI 返回的代码是否一次就成功了？如果修改了 Prompt，你改了什么？

方法论反思

3. "数量最多 ≠ 质量最高"，你还能想到生活中哪些类似的误区？
4. 条形图、分组条形图、饼图各自最适合回答什么类型的问题？

[解释]

回顾今天学了什么

今天用了三种图表：普通条形图回答“谁最多”，分组条形图回答“多的里面结构如何”，饼图回答“整体比例是什么”。每种图对应不同层次的问题。另外，回想一下你和 AI 协作的过程——如果你修改过 Prompt，想想你改了什么、为什么改。这个“试错→调整”的经验比记住代码本身更重要。

下讲预告：总量排名的陷阱

反思刚才的图表

大家刚才画的条形图清晰显示了"哪个城市景区最多"。但排名第一的城市：

- 可能包含了大量免费的街心公园；
- 可能有很多评分等于 0 的废弃景区；
- 平均门票价格也许被这些低质记录严重拉低。

总量排名掩盖了质量分布。

下一讲的工具

为了看穿这种聚合欺骗，我们需要把每条记录拆开、逐点显示：

工具	用途
散点图	把评分和价格逐点对比
箱线图	对比各组的中位数和离群值

下一讲的核心问题：数量最多的城市，真的是性价比最高的旅游目的地吗？

[解释]

条形图排名的局限性

这一页是对本讲所有实操成果的反思。条形图只能回答"谁多谁少"，但无法揭示更深层的问题：排名第一的城市里有多少是免费街心公园？有多少评分接近零的废弃景点？如果大量低质记录充入排名，"总量冠军"可能毫无参考价值。下一讲会引入散点图和箱线图，把每条记录单独展开，验证总量排名是否经得起检验。